

Univerzitet u Nišu, Elektronski fakultet
Katedra za računarstvo



Studijski program: Veštačka inteligencija i mašinsko učenje

Predmet: Stručna praksa

Izveštaj

Razvoj i evaluacija modula za detekciju AI-generisanih video-zapisa

Kompanija:

UM CARUJE DOO

Komisija: prof. dr Leonid Stoimenov
prof. dr Dragan Stojanović
prof. dr Milorad Tošić
prof. dr Ivan Petković

Student: Aleksandar Cvetanović

Broj indeksa: 2017

Niš, 2026

Sadržaj

1 O KOMPANIJI.....	2
2 ZADACI STRUČNE PRAKSE.....	2
2.1 FUNKCIONALNI ZAHTEVI.....	2
2.2 NEFUNKCIONALNI ZAHTEVI I OGRANIČENJA.....	3
2.3 SOFTVERSKO I HARDVERSKO OKRUŽENJE.....	3
3 SAMOSTALNI RAD U PRIPREMI I OBAVLJANJU PRAKSE.....	3
4 REALIZACIJA STRUČNE PRAKSE.....	4
4.1 PRIPREMA SKUPOVA PODATAKA.....	4
4.2 OBRADA VIDEA I IZDVAJANJE KARAKTERISTIKA.....	4
4.3 MODELI I EKSPERIMENTALNI NALAZI.....	5
4.4 BACKEND I FRAME-LEVEL DIJAGNOSTIKA.....	6
4.5 EVALUACIJA I TRENUTNO STANJE.....	8
5 ZAKLJUČAK.....	9
6 LITERATURA.....	10

1 O kompaniji

Stručnu praksu realizovao sam u kompaniji **UM CARUJE DOO**, u kojoj sam zaposlen na poziciji AI/ML inženjera od Februara 2026. Zbog toga su aktivnosti opisane u ovom izveštaju bile deo mojih redovnih radnih zadataka.

UM CARUJE DOO se bavi razvojem softverskih rešenja i primenom veštačke inteligencije u analizi digitalnog sadržaja. Jedan od proizvoda na kojima kompanija radi je SkrewAI, sistem usmeren na proverljivo poreklo i autentičnost fotografija i video-zapisa. Osnovni koncept proizvoda zasniva se na povezivanju snimljenog sadržaja sa senzorskim podacima uređaja i kriptografskim dokazima koji omogućavaju naknadnu proveru porekla sadržaja [6].

Tokom stručne prakse radio sam na eksperimentalnom modulu namenjenom naknadnoj analizi gotovih video-zapisa. Cilj modula je da za svaki analizirani kadar prikaže koliko njegove vizuelne i vremenske karakteristike odgovaraju karakteristikama izlaza poznatih modela za generisanje videa. Modul ne predstavlja kriptografski dokaz autentičnosti i nije zamena za osnovni pristup sistema SkrewAI. On predstavlja dodatni analitički alat koji je još u fazi istraživanja, razvoja i testiranja i nije pušten u produkciju.

Mentor stručne prakse bio je Milan Gligorijević, Technical Lead. Sa mentorom sam diskutovao namenu modula, pravac istraživanja, prioritete u razvoju, način povezivanja modela sa aplikacijom i ograničenja koja moraju biti jasno predstavljena korisniku. Posebna pažnja posvećena je tome da rezultat bude razumljiv na nivou pojedinačnih kadrova, a ne samo kao jedna konačna ocena za ceo video-zapis.

2 Zadaci stručne prakse

Glavni zadatak stručne prakse bio je istraživanje i razvoj modula za detekciju AI-generisanih video-zapisa sa izlazom na nivou pojedinačnih kadrova. Rad je obuhvatio ceo razvojni tok: pripremu podataka, analizu postojećih metoda, treniranje i poređenje modela, proveru generalizacije i povezivanje izabranog pristupa sa serverskom aplikacijom.

2.1 Funkcionalni zahtevi

- prijem i osnovna provera video-zapisa koji korisnik prosledi aplikaciji
- podela videa na scene i izbor kadrova koji se mogu pouzdano analizirati
- izdvajanje prostornih i vremenskih karakteristika iz izabranih kadrova
- računanje zasebnog skora i klase za svaki analizirani kadar
- povezivanje rezultata sa vremenskom oznakom i pozicijom u izvornom videu
- prikaz rezultata kroz vremensku liniju, galeriju kadrova i pregled izabranog kadra
- formiranje sažete video-level ocene radi lakšeg pregleda, bez gubitka detaljnih frame-level rezultata

2.2 Nefunkcionalni zahtevi i ograničenja

Pored osnovnih funkcionalnosti, sistem je morao da bude ponovljiv i proverljiv i u fazi testiranja i razvoja. Za svaki eksperiment čuvani su parametri, verzije modela, podela podataka i rezultati. Obrada većeg broja videa organizovana je tako da može bezbedno da se prekine i nastavi, bez ponovnog izračunavanja već uspešno obrađenih primera, što je bilo neophodno u radu sa eksperimentima koji traju jako dugo, gde mala greška ili nestabilnost sistema mogu dovesti u pitanje sate prethodnog rada.

Najvažnije ograničenje predstavlja promena domena. Video koji je kompresovan na društvenoj mreži, snimljen drugim uređajem ili generisan novim modelom može imati drugačiju raspodelu karakteristika od materijala korišćenog tokom treniranja. Zbog toga dobar rezultat na internom test skupu nije dovoljan. Model je proveravan i na odvojenim benchmark i OOD skupovima, a posebna pažnja posvećena je lažno pozitivnim rezultatima na realnim videima.

2.3 Softversko i hardversko okruženje

Oblast	Korišćene tehnologije
Razvoj modela	Python, PyTorch, CUDA, scikit-learn, NumPy, pandas, SciPy
Video i računarski vid	OpenCV, FFmpeg/ffprobe, PySceneDetect
Reprezentacije	CLIP ViT-L/14 i DINOv3 ViT-L/16
Backend	FastAPI, Uvicorn, Pydantic, REST/JSON, SQLite
Razvojno okruženje	Linux, Git, Bitbucket, 2x NVIDIA RTX 3090

Tabela 1. Najvažnije tehnologije korišćene tokom stručne prakse

3 Samostalni rad u pripremi i obavljanju prakse

Pre implementacije bilo je potrebno proučiti postojeće pristupe detekciji generisanog video-sadržaja. Kao polazna tačka korišćen je STALL, metod koji iz DINOv3 reprezentacija posmatra prostorne osobine kadra i promene između susednih kadrova [1]. Analiziran je i ForgeLens, pristup razvijen za detekciju falsifikovanih slika koji pomoću dodatnih WSGM i FAFormer modula usmerava zamrznuti vizuelni model ka obeležjima relevantnim za detekciju [2]. AIGVDBench je korišćen kao izvor video-podataka i kao referenca za raznovrsnost generatora, modaliteta i sadržaja [3].

Posebno sam proučio osobine dva vizuelna enkodera. CLIP je razvijen učenjem veze između slika i tekstualnih opisa i u ovom projektu je korišćen za izdvajanje opšte vizuelne reprezentacije svakog kadra [4]. DINOv3 je samonadgledani vizuelni enkoder čije su reprezentacije korišćene za analizu izgleda, ali i za računanje promena između kadrova [5].

Važan deo samostalnog rada odnosio se na eksperimentalni protokol. Analizirao sam kako nastaju neželjena preklapanja između skupova, kako isti sadržaj može da se pojavi u više kolekcija posle ponovnog kodovanja i zašto fake-real parovi moraju da ostanu u istoj atomskoj grupi. Zbog toga su korišćene provere tačnih duplikata, perceptivnih sličnosti i porekla video-zapisa. Podela

podataka je pravljena tako da isti sadržaj, fizički uređaj ili povezani par ne pređe iz trening dela u validacioni ili test deo.

Za vrednovanje modela korišćene su threshold-independent metrike ROC-AUC, parcijalni ROC-AUC pri niskoj stopi lažno pozitivnih rezultata i Average Precision, kao i precision, recall i F1 pri pragu izabranom isključivo na validacionom skupu. Ovaj način evaluacije bio je važan jer je cilj bio da sistem ne označava veliki broj realnih videa kao generisane. Naučio sam i da prag koji dobro radi na internom skupu često ne može neposredno da se prenese na nov izvor podataka, čak i kada sam model i dalje dobro rangira primere.

Tokom rada poređene su jednostavne linearne metode, višeslojne neuronske mreže, CNN, GRU i LSTM varijante, kao i kombinacije CLIP i DINOv3 grana. Posebno koristan zaključak bio je da složenija arhitektura ne daje automatski bolju generalizaciju. Jednostavniji frame-level model često je bio stabilniji od dubljih vremenskih mreža, dok su vremenske karakteristike bile korisne kao dopunski signal na pojedinim spoljašnjim skupovima.

4 Realizacija stručne prakse

4.1 Priprema skupova podataka


Rad je započet analizom postojećih kolekcija realnih i AI-generisanih videa. Izvori su organizovani prema skupu podataka, generatoru, modalitetu generisanja i poreklu realnog materijala. Manipulisani realni snimci nisu tretirani kao potpuno generisani video-zapisi. Konačna podela je sadržala odvojene trening, validacioni i test skup, dok su dodatni skupovi sa nepoznatim generatorima i drugačijim realnim izvorima korišćeni za proveru generalizacije.

Realna klasa dopunjena je videima sa različitih mobilnih uređaja kako model ne bi naučio samo razliku između nekoliko konkretnih benchmark kolekcija. Kod skupova sa poznatim fake-real parovima očuvana je veza između generisanog videa i njegovog izvora. Pre konačne podele izvršene su provere identičnih fajlova i sadržajno veoma sličnih videa. Na ovaj način smanjen je rizik da model tokom testiranja vidi isti sadržaj koji je već korišćen za trening.

4.2 Obrada videa i izdvajanje karakteristika

Backend najpre proverava da li je video moguće otvoriti i analizirati, a zatim detektuje granice scena. Kadrovi se biraju unutar scena brzinom od osam kadrova u sekundi, tako da jedna sekvenca ne prelazi preko reza između dve različite scene. Suviše kratke scene se evidentiraju i preskaču. Za svaki izabrani kadar čuvaju se indeks u izvornom videu i vremenska oznaka, što omogućava direktno povezivanje modelskog rezultata sa prikazom u korisničkom interfejsu.

Tok rada modula za frame-level analizu video-zapisa



UML dijagram. Tok rada modula za frame-level analizu video-zapisa

CLIP grana za svaki analizirani kadar daje 1024-dimenzionalnu reprezentaciju njegovog vizuelnog sadržaja. DINOv3 reprezentacije koriste se za izvođenje vremenskih karakteristika koje opisuju promene u okviru iste scene. Ove dve grupe karakteristika prosleđuju se treniranoj klasifikacionoj glavi. Izlaz nije samo jedna odluka za video, već uređena linija skorova. Svaki element linije pripada konkretnom kadru i može se pregledati zasebno.

4.3 Modeli i eksperimentalni nalazi

U eksperimentima su prvo proverene jednostavne klasifikacione glave nad zamrznutim CLIP i DINOv3 reprezentacijama. Poređeni su logistička regresija, SVM i različite višeslojne neuronske mreže. Zatim su ispitani vremenski modeli zasnovani na GRU i LSTM slojevima, CNN varijante i modeli koji spajaju prostorne i vremenske signale. Svaka grupa modela trenirana je na istoj podeli i evaluirana istim metrikama kako bi poređenje bilo što pravednije.

Nalaz	Praktično značenje
CLIP je bio najstabilniji samostalni signal.	Izgled pojedinačnog kadra ostaje važna osnova frame-level dijagnostike.
DINOv3 je davao komplementarne rezultate na pojedinim OOD skupovima.	Vremenski signal ima smisla kao dopuna, ali ne zamenjuje prostorni model.
Dublji vremenski modeli nisu davali dosledno poboljšanje.	Veća složenost se ne uvodi bez jasnog dobitka na više skupova.
Kompresija menja raspodelu karakteristika.	Model mora posebno da se proverava na ponovo kodovanim

Nalaz	Praktično značenje
	videima.
Prag sa internog skupa ne prenosi se uvek na novi domen.	Kalibracija mora da koristi reprezentativne validacione podatke.


Tabela 3. Najvažniji zaključci eksperimentalnog rada

Rezultati su pokazali da interni test skup može biti veoma lak u poređenju sa stvarnim promenama domena. Zbog toga spoljašnji skupovi nisu korišćeni za naknadno prilagođavanje arhitekture ili praga, već kao dijagnostika. Posebno je analiziran uticaj H.264 kompresije. Dodavanje kompresovanih primera tokom treninga poboljšalo je rezultate na jako kompresovanim videima, ali je u pojedinim slučajevima smanjilo rezultat na čistim podacima. Taj kompromis je jedan od razloga zbog kojih modul ostaje u testnoj fazi.

4.4 Backend i frame-level dijagnostika


Serverska aplikacija je organizovana tako da obrada modela bude odvojena od HTTP sloja, evidencije poslova i čuvanja rezultata. Nakon slanja videa kreira se asinhroni zadatak. Rezultat svakog analiziranog kadra sadrži redni broj, indeks izvornog kadra, vremensku oznaku, numerički skor, procenjenu klasu i odgovarajuću sliku. Backend proverava da li su indeksi uzastopni, vremena uređena i skorovi u dozvoljenom opsegu pre nego što rezultat postane dostupan korisničkom interfejsu.

Klasifikacija se obavlja na jednom mestu: kadar se označava kao kompatibilan sa poznatim AI modelima kada njegov skor dostigne prag koji je vratio model. Video-level skor računa se kao srednja vrednost frame-level skorova i služi kao sažetak, dok vremenska linija i pojedinačni kadrovi ostaju glavni dijagnostički izlaz. Ovakav prikaz omogućava da korisnik vidi da li je signal prisutan kroz ceo video ili samo u njegovom ograničenom delu.



Slika 1. Glavni prikaz modula: analizirani kadar, vremenska linija i pregled frame-level skorova

Pored glavnog rezultata postoji odvojena grana sa forenzičkim merenjima kamere i kretanja. Ona radi nad sopstvenim intervalima i ne menja frame-level klasifikaciju. Njena svrha je da prikaže dodatne merljive osobine, kao što su karakteristike optičkog toka, stabilizacije, šuma i obrade slike. U interfejsu je zato jasno naznačeno da jačina i pogodnost merenja nisu verovatnoće AI sadržaja i da se ne porede direktno između različitih detektora.



Slika 2. Odvojeni prikaz nezavisnog forenzičkog merenja zasnovanog na kretanju kamere

4.5 Evaluacija i trenutno stanje

Modeli su prvo birani na validacionom skupu. Tek nakon zaključavanja arhitekture i načina treniranja pokretana je evaluacija na test skupu. Dodatne kolekcije sa drugim generatorima, drugačijim realnim snimcima i različitim nivoima kompresije korišćene su za proveru ponašanja van trening raspodele. Na njima su posmatrani kako ukupna sposobnost rangiranja, tako i stopa pogrešnog označavanja realnih videa.

Trenutna verzija demonstrira ceo tok od prijema videa do frame-level rezultata i prikaza u interfejsu. Ipak, evaluacija je pokazala da se performanse menjaju u zavisnosti od izvora, generatora i kompresije. Zbog toga projekat nije predstavljen kao gotov produkcionu detektor. Pre produkcione primene potrebno je proširiti reprezentativan validacioni skup, ponovo odrediti radni prag i proveriti ponašanje na novim generatorima i stvarnim korisničkim snimcima.

5 Zaključak

Tokom stručne prakse učestvovao sam u razvoju eksperimentalnog modula za detekciju AI-generisanih video-zapisa. Rad je obuhvatio pripremu i proveru skupova podataka, izdvajanje vizuelnih reprezentacija, treniranje i poređenje različitih modela, evaluaciju na internim i spoljašnjim skupovima i integraciju rezultata u backend i korisnički interfejs.

Najvažniji praktični rezultat je frame-level dijagnostika. Umesto samo jedne oznake za ceo video, sistem čuva skor, klasu, vremensku poziciju i prikaz svakog analiziranog kadra. Time je rezultat pregledniji i omogućava korisniku da uoči delove videa koji najviše utiču na procenu. Video-level vrednost ostaje koristan sažetak, ali nije jedini izvor informacije.

Za mene je posebno korisno bilo povezivanje istraživačkog i inženjerskog dela posla. Pored rada sa neuronskim mrežama, naučio sam koliko su važne kontrola porekla podataka, sprečavanje curenja između skupova, pravilno razdvajanje validacije i testa, evidentiranje eksperimenata i jasna komunikacija ograničenja modela. Diskusije sa mentorom pomogle su da se istraživačke ideje prevedu u funkcionalnost koja je razumljiva korisniku.

Glavni problemi ostaju generalizacija na nove generatore, promena karakteristika usled kompresije i izbor praga koji neće stvarati veliki broj lažno pozitivnih rezultata. Zbog toga je modul trenutno u testnoj fazi. Dalji rad treba usmeriti na raznovrsnije podatke, pouzdaniju kalibraciju i proveru na novim, unapred zaključenim OOD skupovima. Takođe, možda i najveće ograničenje predstavlja nedostatak kvalitetnih javnih skupova podataka koji bi obuhvatiti najnovije generatore i dovoljno raznovrstnog realnog sadržaja.

6 Literatura

- [1] O. Ben Hayun, R. Betser, M. Y. Levi, L. Kassel i G. Gilboa, „Training-free Detection of Generated Videos via Spatial-Temporal Likelihoods“, *CVPR*, 2026.
- [2] Y. Chen, L. Zhang i Y. Niu, „ForgeLens: Data-Efficient Forgery Focus for Generalizable Forgery Image Detection“, *arXiv:2408.13697*, 2025.
- [3] L. Ma i dr., „Your One-Stop Solution for AI-Generated Video Detection“, *arXiv:2601.11035*, 2026.
- [4] A. Radford i dr., „Learning Transferable Visual Models From Natural Language Supervision“, *Proceedings of ICML*, 2021.
- [5] O. Siméoni i dr., „DINOv3“, *arXiv:2508.10104*, 2025.
- [6] SkrewAI, zvanična internet prezentacija, <https://skrew.ai/>, pristupljeno 18.09.2026.
- [7] UM CARUJE DOO, zvanična internet prezentacija, <https://umcaruje.net/>, pristupljeno 18.09.2026.